INF-8239 · Ejercicio 06: Motor Recomendador Reproducible

Programa: Maestría en Inteligencia Artificial · Universidad Autónoma de Santo Domingo (UASD)

Asignatura: Ciencia de Datos II | **Docente:** Edwin Ramón José Nolasco

Estudiante: Juan Aníbal Pérez | **Fecha:** Octubre 2026

Enlace al Repositorio GitHub: https://github.com/sistemasperez/CienciaDatos2-U03.E06

Metodología, Datos y Control de Fuga (Data Leakage)

El proyecto utiliza Fashion-MNIST (Zalando Research, licencia MIT), integrado por 70,000 imágenes monocanal en escala de grises distribuidas equitativamente en 10 clases de indumentaria (6,000 ejemplos de entrenamiento y 1,000 de prueba por categoría):

- **Campos del dataset**: Matrices images de 28 × 28 × 1 píxeles normalizadas analíticamente a reales en [0.0, 1.0] (float32), y enteros labels {0, ..., 9} que mapean las clases: 0: T-shirt/top, 1: Trouser, 2: Pullover, 3: Dress, 4: Coat, 5: Sandal, 6: Shirt, 7: Sneaker, 8: Bag y 9: Ankle boot.
- **Partición y Control de Fuga:** La normalización se realiza por división fija escalar (x / 255.0), sin estimar medias y desviaciones sobre el conjunto de test. Los modelos se entrenaron exclusivamente con x_train (60,000 filas). El conjunto x_test (10,000 filas) se mantuvo estrictamente aislado hasta la evaluación final fuera de muestra.

Usamos el **autoencoder clásico,** que usa tanto un encoder como un decorer. El encoder resume la información de la imagen (como si fuera comprimirlas) y el decoder las descomprime. Este autoencoder tiene sus limitaciones ya que no funciona como modelo regenerativo, a diferencia del VAE (Variational Encoder) que supera estas limitaciones. Estas limitaciones del autoencoder vienen porque el espacio donde ser representa la imagen comprimida es discontinuo y los puntos (x,y) están super dispersos. En cambio, en el encoder variacional, los datos no están discontinuos: usa la Divergencia KL para que los puntos estén lo más agrupados posible y el espacio se vuelva continuo.

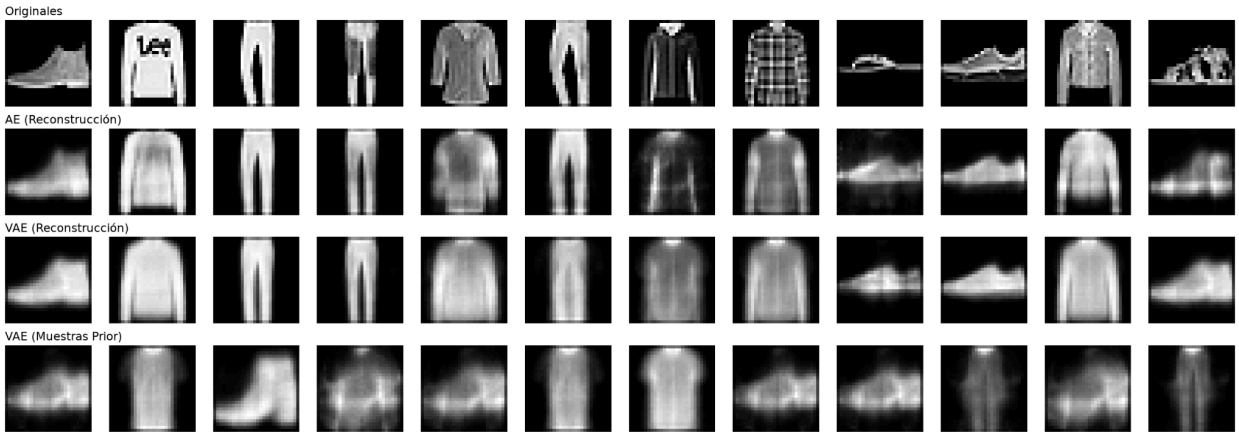
Resultados

Evaluación cuantitativa sobre las 10,000 imágenes del conjunto de prueba independiente de Fashion-MNIST (28 × 28 × 1):

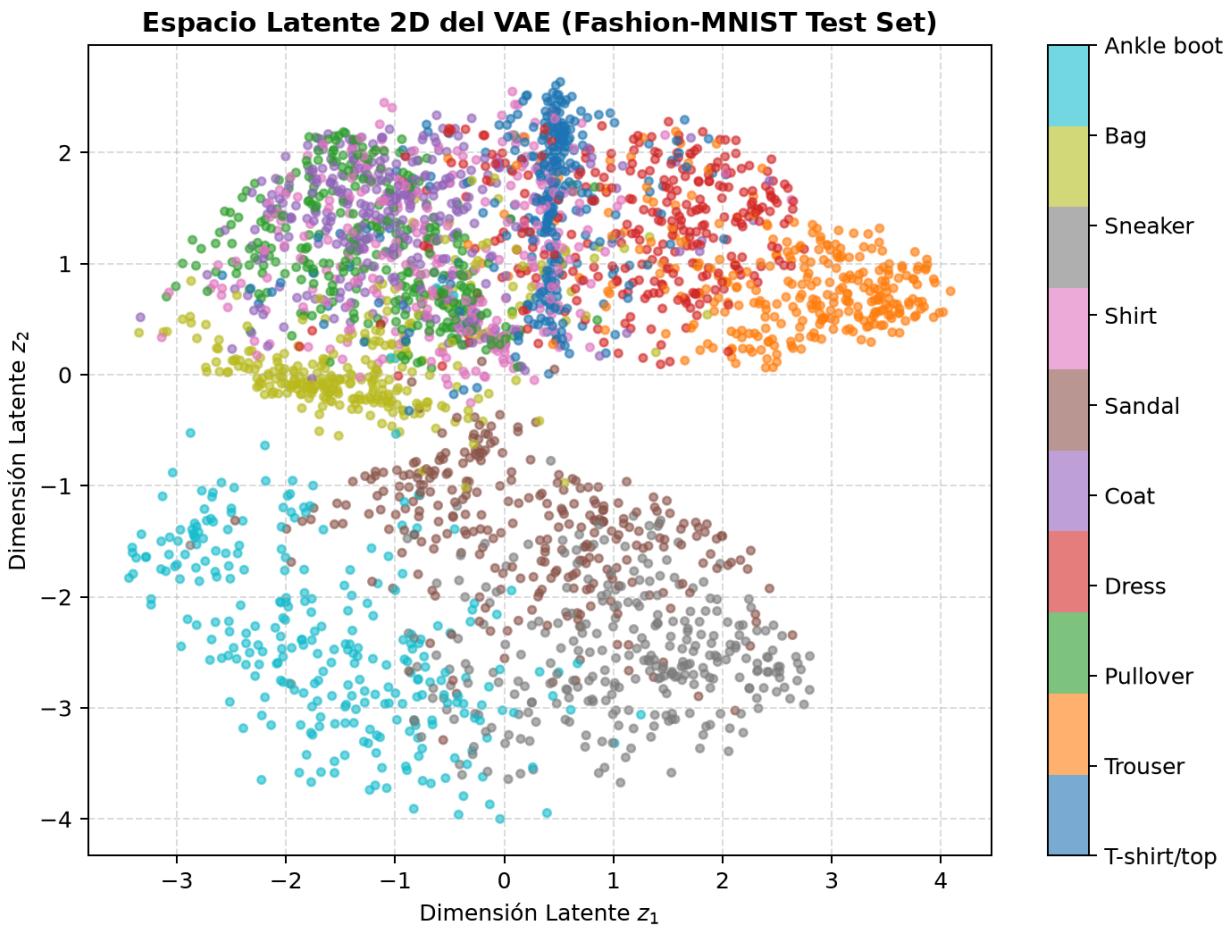
Modelo / Enfoque	Espacio Latente (*D*)	Parámetros	Tiempo Entrenamiento	Reconstrucción Test (BCE)	Reconstrucción Test (MSE)	Regularización KL	Distancia Mínima	Diversidad Muestral	Tamaño Modelo

							a Train (L_2)		
Autoencoder Estándar (Baseline)	16	25,888	7.86 s	0.3068	0.02029	N/A (Discontinuo)	N/A (No Generativo)	N/A	330.66 KB
VAE (Variational Autoencoder) Generativo	2	202,516	12.44 s	0.3405	0.03299	6.3018	1.6831	5.8485	415.66 KB

Análisis de Reconstrucción, Muestreo e Interpolación



.Comparativa de 12 muestras: Originales, Reconstrucción AE, Reconstrucción VAE y Muestras desde el prior $z \sim N(0, I_2)$.



Proyección 2D del espacio latente coloreado por las 10 clases de Fashion-MNIST.

En esta gráfica podemos ver cada punto (z1, z2) el espacio latente generado (el espacio latente es un espacio que resume la imagen de 784 píxeles en un mapa mental de coordenadas). Cada puntito en la gráfica es una prenda de vestir real del conjunto de prueba. El color de cada punto indica la categoría real de la prenda (zapatos, pantalones, camisas, etc.).

Cabe destacar que los colores no están regados al azar; se agruparon por familias de forma espontánea. Se puede ver que los calzados están agrupados la mayor parte en la parte inferior (z2 < 0), los pantalones estan aislados a la derecha (z1 > 2), las camisas están en la parte superior (z2 > 0) y asi sucesivamente. Esto demuestra cómo el modelo organizó el espacio por similitud visual sin supervisión.

Auditoría de No-Memorización (Nearest Neighbors) y Diversidad

Se calculó la distancia **euclidiana mínima** entre 500 muestras sintéticas generadas y las imágenes de entrenamiento reales mediante Nearest Neighbors. La distancia mínima fue de 1.6831 (y promedio de 2.9571). Al ser significativamente mayor que cero, se comprueba que el

VAE no memoriza ni clona instancias existentes, sino que sintetiza nuevas prendas dentro de la variedad continua aprendida con una diversidad media intra-muestral de 5.8485.

Costo Computacional, Límites y Conclusiones

El Autoencoder requirió 7.86 s (25,888 parámetros, 330.66 KB) y el VAE 12.44 s (202,516 parámetros, 415.66 KB) en CPU estándar.

Entre las principales limitaciones del modelo están la drástica reducción dimensional del espacio latente a solo dos dimensiones (D = 2), la cual facilita la visualización e interactividad directa en la aplicación Streamlit (app/streamlit_app.py), pero a costa de suprimir texturas de alta frecuencia y generar reconstrucciones con bordes difusos.

Consideraciones éticas y de privacidad: La generación de datos sintéticos no garantiza implícitamente la privacidad matemática de los datos de entrenamiento a menos que se incorporen mecanismos explícitos como el Descenso de Gradiente Estocástico con Privacidad Diferencial (DP-SGD).

Declaración de Uso Ético y Responsable de IA

Se contó con asistencia de Gemini 3.8 Flash (High) vía Antigravity IDE para depuración de pruebas automatizadas con pytest, vectorización de distancias de vecinos más cercanos y estructuración del Model Card. Por mi parte, se realizaron las ecuaciones analíticas de divergencia KL y reparametrización, comprobó el 100% de las 8 pruebas unitarias y asumo la autoría y responsabilidad íntegra de la entrega.